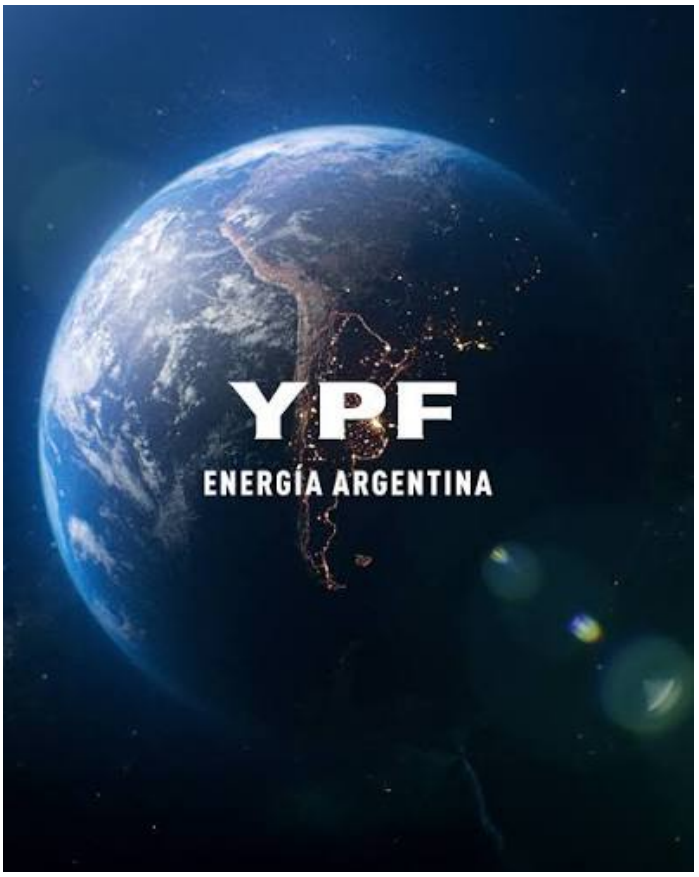
“Analisis de Eficiencia Academica y Retencion en las Universidades Publicas Argentinas”



Programa: EnergIA Digital - Data Science (Fundacion YPF)

Proyecto Final - Pre-Entregas 2 y 3

Participantes: Altamirano, Marianella (47083878)
Sotelo, Ulises ()

FUNDACIÓN YPF

Resumen del Proyecto:

Este proyecto analiza los determinantes estructurales e institucionales vinculados a la regularidad y el rendimiento academico de los estudiantes en las instituciones universitarias publicas de Argentina. A traves de tecnicas de Ciencia de Datos y Aprendizaje Automatico Supervisado, se modela y predice la tasa de retencion estudiantil.

Origen de los Datos:

Los datos fueron obtenidos de fuentes oficiales del Ministerio de Capital Humano / Secretaria de Educacion de la Nacion:

- Anuario Estadistico Universitario 2024 (el ultimo disponible con fecha mas reciente).
  - Cuadro 1.2.2: Indicadores de Recursos Humanos (planta docente universitaria y dedicacion horaria).
  - Programa Nacional de Becas Estrategicas Manuel Belgrano 2024.

Objetivo:

El objetivo nuestro fue predecir si una universidad presenta una "Alta tasa de retencion/regularidad academica" (estudiantes reinscriptos con 2 o mas materias aprobadas) en funcion de variables estructurales: ratio alumno/docente, perfil de ingresantes, dedicacion horaria del cuerpo docente y tamaño institucional.

Hallazgos del Analisis Exploratorio (EDA):

Escala VS. Rendimiento: El tamaño masivo de una institucion no garantiza por si solo mayor regularidad; existen universidades medianas con indices de aprobacion proporcionalmente superiores.
Dedicación Docente: La proporcion de cargos docentes con dedicacion exclusiva presenta una relacion positiva con los niveles de retencion.
Presencia de Outliers: Instituciones como la *UBA* presentan volúmenes de estudiantes atipicos respecto a la media del sistema, requiriendo metodos de escalado robustos.

Modelos Evaluados y Optimizacion:

- **Preprocesamiento:** Imputacion de faltantes por mediana y estandarización con StandardScaler integrado en un Pipeline de Scikit-Learn para evitar fuga de informacion.
- **Algoritmo Seleccionado:** Ensamble "Random Forest Classifier".
- **Control de Sobreajuste (Overfitting):** Optimizacion de hiperparametros (`max_depth`, `n_estimators`, `min_samples_leaf`) mediante `GridSearchCV` sobre una validación cruzada estratificada de 5 pliegues (`StratifiedKFold`).